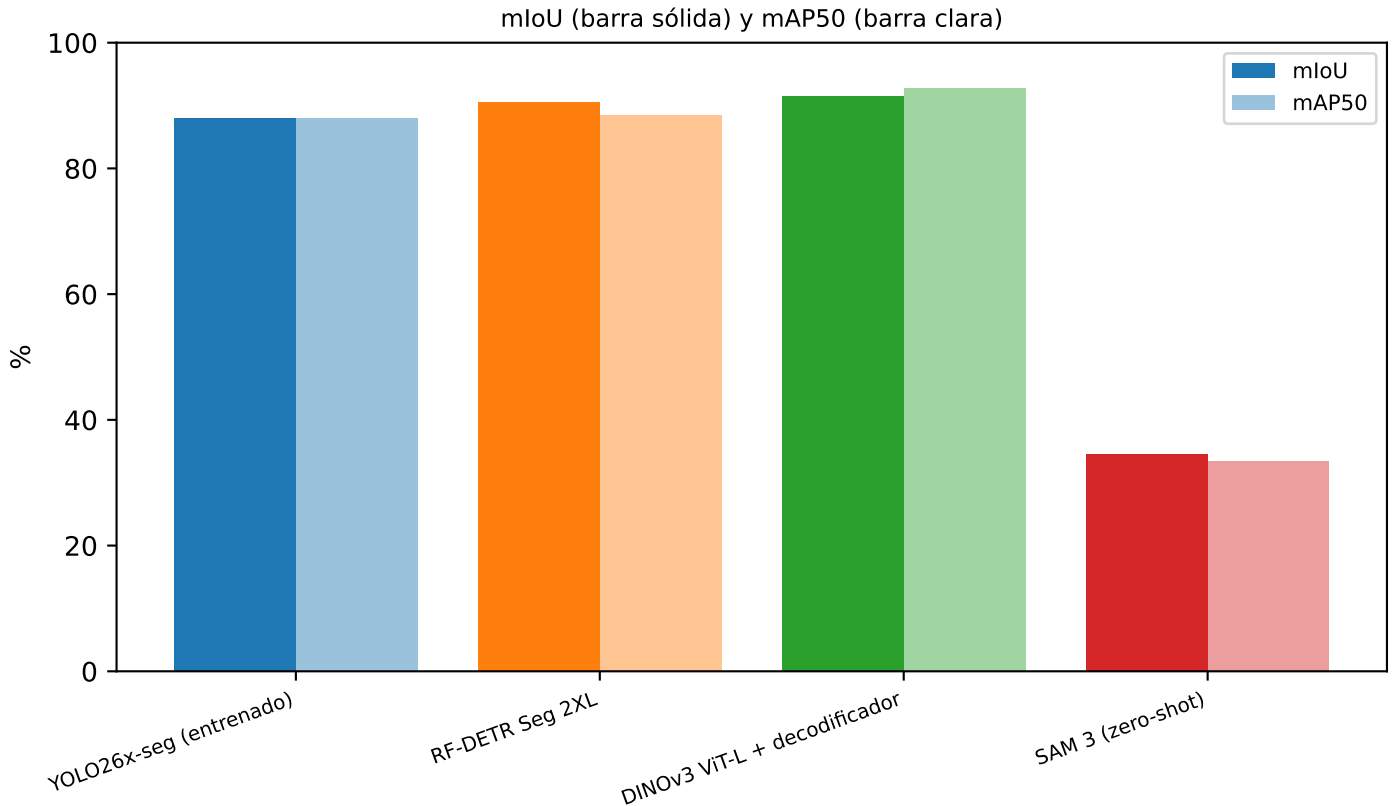
Comparativa de modelos de segmentación de piezas de coche

Dataset VehicleSeg10K · test = split 'valid' (3069 imágenes) · 12/11/2026

Mejor modelo por mIoU: DINOv3 ViT-L + decodificador (91.5 %).

Umbral de confianza para mapas y detección: 0.25. Pieza acertada si IoU ≥ 0.5.

Modelo	mIoU	mAcc	mDice	mAP50	mAP50-95	F1 piezas	ms/fotog.
YOLO26x-seg (entrenado)	87.9	95.5	93.5	88.0	76.2	92.0	38
RF-DETR Seg 2XL	90.6	94.4	95.0	88.5	73.9	91.2	77
DINOv3 ViT-L + decodificador	91.5	95.3	95.5	92.7	79.8	93.2	1228
SAM 3 (zero-shot)	34.6	50.4	42.4	33.5	24.1	36.0	1342



Hardware, tiempo por fotograma y memoria

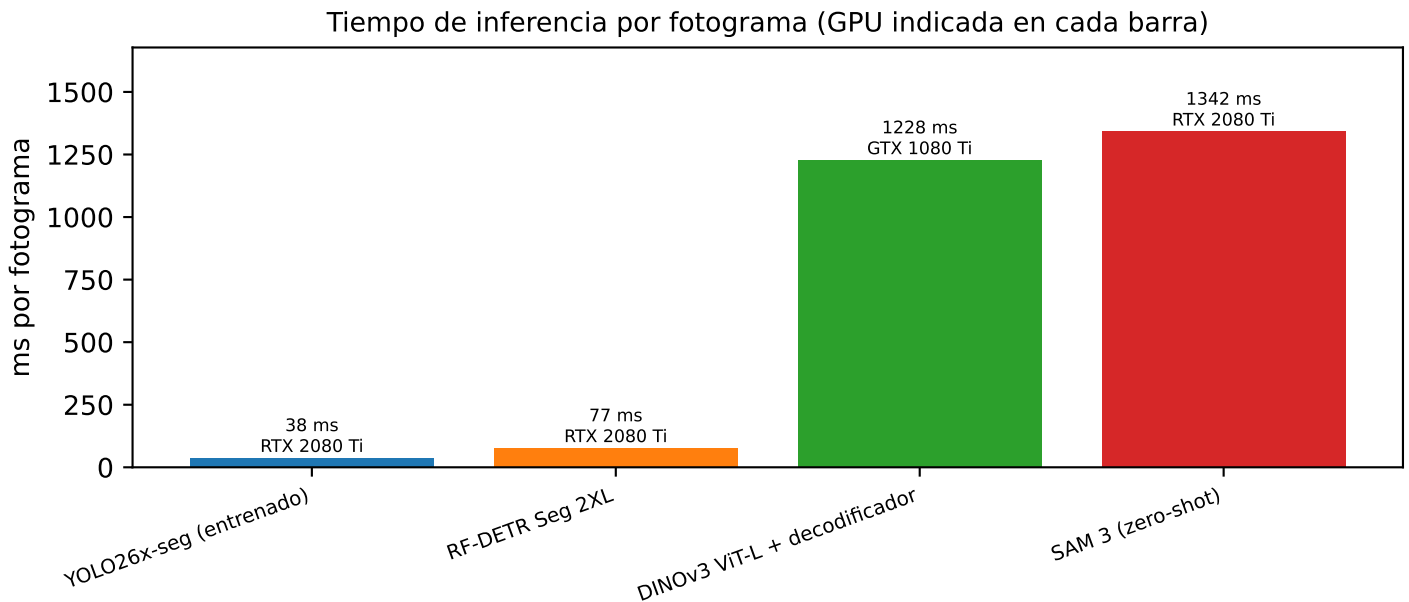
Servidores. Dos nodos con 4 GPUs cada uno, que comparten el mismo disco: uno con 4× NVIDIA GeForce RTX 2080 Ti (11 GB, arquitectura Turing) y otro con 4× NVIDIA GeForce GTX 1080 Ti (11 GB, Pascal). Ninguna de las dos tiene bfloat16 por hardware, así que la media precisión es float16.

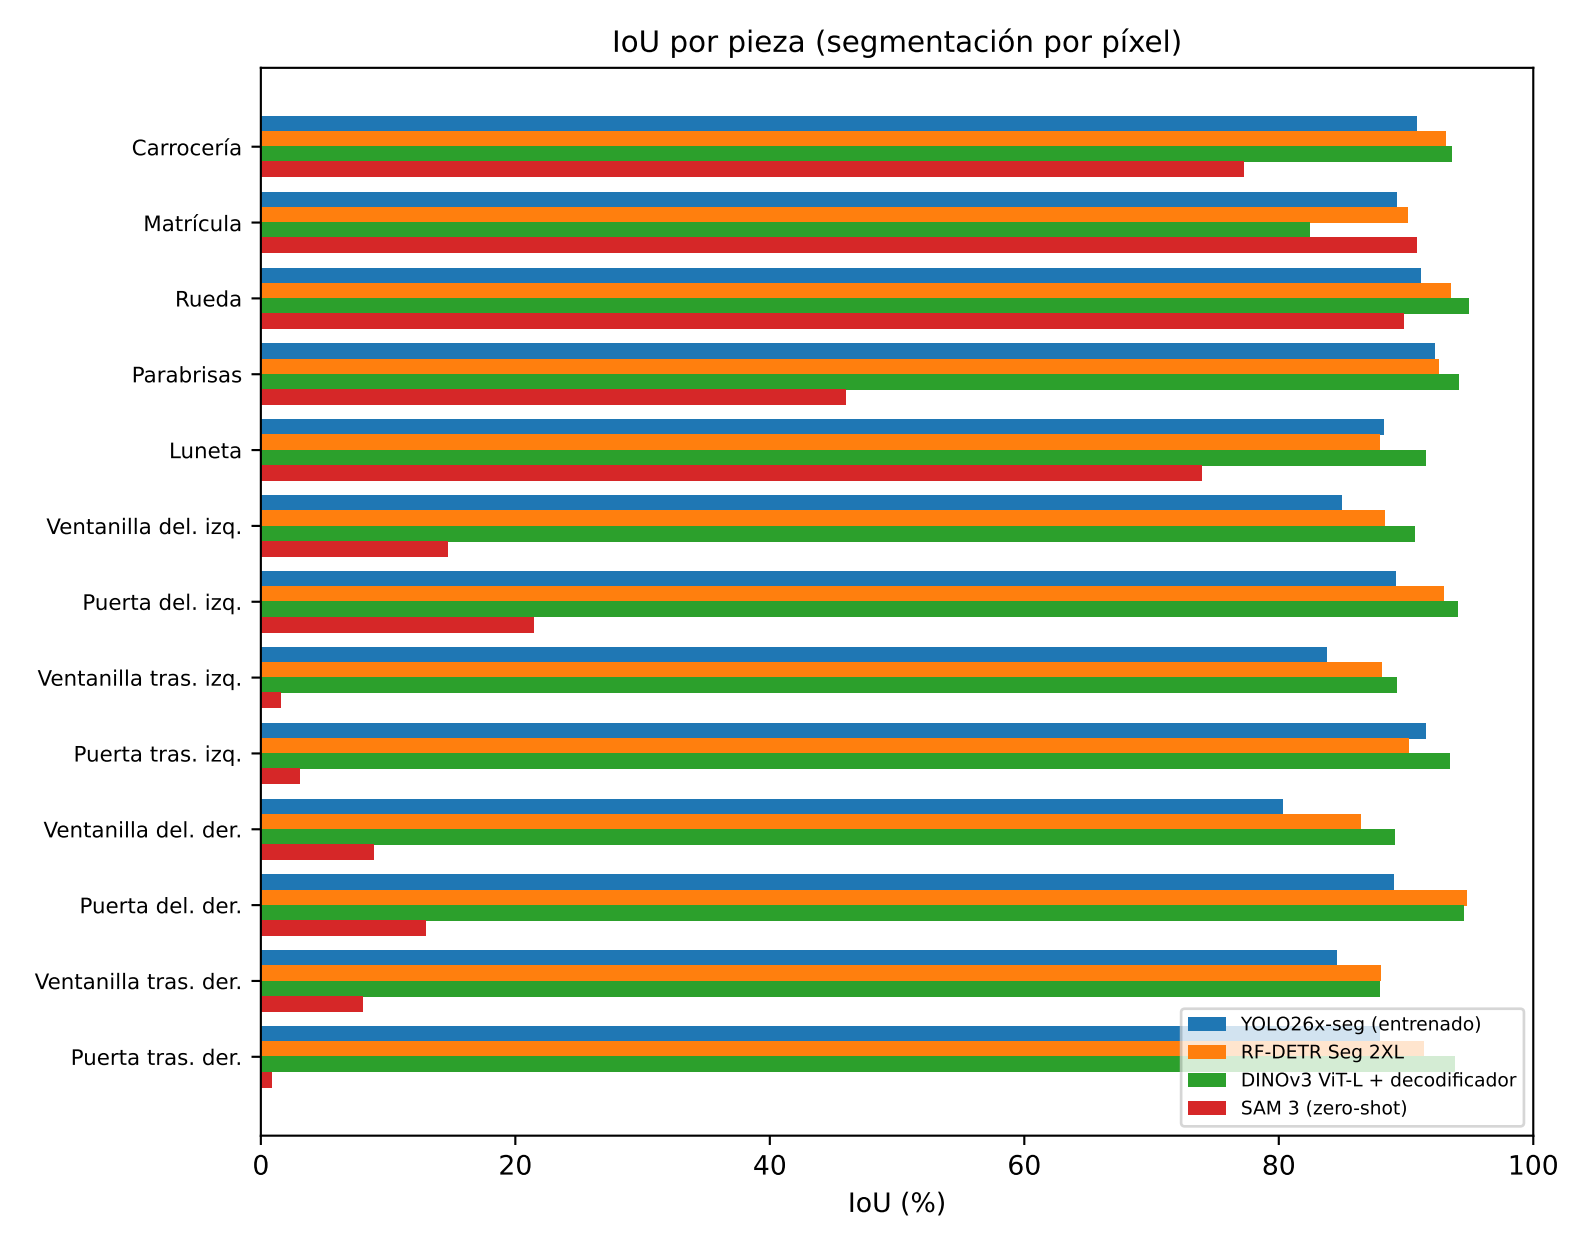
Tiempo por fotograma. Se mide con una sola GPU y lote 1, desde la imagen ya decodificada en memoria hasta tener las máscaras: incluye preprocesado, red y postprocesado, pero no la lectura del disco. Se descarta la primera imagen (calentamiento). Las fotos del test son grandes (hasta ~12 Mpx) y las máscaras se devuelven a la resolución original, así que el postprocesado pesa. SAM 3 hace una consulta de texto por pieza (13 por foto). Si la inferencia se reparte en varias GPUs, el tiempo es el de cada GPU, no el total dividido.

Memoria. 'VRAM pico' es la memoria de GPU máxima que reservó PyTorch durante toda la inferencia (modelo + activaciones); es lo que necesita como mínimo la GPU. 'Tamaño fp32' es el número de parámetros por 4 bytes. '-' indica que esas predicciones se generaron antes de medirlo.

Ojo: los modelos que se ejecutaron en la GTX 1080 Ti no se pueden comparar en velocidad de tú a tú con los de la RTX 2080 Ti: la 1080 Ti es más lenta y, al no tener núcleos tensor, en float16 va mucho más despacio.

Modelo	Entrenado en	Inferencia en	ms/fotog. media	ms/fotog. mediana	FPS	Parámetros (M)	Tamaño fp32 (MB)	VRAM pico (GB)
YOLO26x-seg (entrenado)	4× RTX 2080 Ti	RTX 2080 Ti	38	35	26.4	71	269	2.6
RF-DETR Seg 2XL	4× RTX 2080 Ti	RTX 2080 Ti	77	68	13.0	38	146	7.4
DINOv3 ViT-L + decodificador	4× GTX 1080 Ti	GTX 1080 Ti	1228	1147	0.8	-	-	-
SAM 3 (zero-shot)	sin entrenar	RTX 2080 Ti	1342	1178	0.7	-	-	-




IoU por pieza (segmentación por píxel)
Carrocería
Matrícula
Rueda
Parabrisas
Luneta
Ventanilla del. izq.
Puerta del. izq.
Ventanilla tras. izq.
Puerta tras. izq.
Ventanilla del. der.
Puerta del. der.
Ventanilla tras. der.
Puerta tras. der.
YOLO26x-seg (entrenado)
RF-DETR Seg 2XL
DINOv3 ViT-L + decodificador
SAM 3 (zero-shot)
0
20
40
60
80
100
IoU (%)

IoU por pieza (%)

Pieza	YOLO26x-seg (entrenado)	RF-DETR Seg 2XL	DINOv3 ViT-L + decodificador	SAM 3 (zero-shot)
Carrocería	90.9	93.1	93.6	77.2
Matrícula	89.3	90.1	82.4	90.8
Rueda	91.1	93.5	94.9	89.8
Parabrisas	92.2	92.6	94.1	45.9
Luneta	88.2	88.0	91.6	73.9
Ventanilla del. izq.	84.9	88.3	90.7	14.7
Puerta del. izq.	89.2	92.9	94.1	21.4
Ventanilla tras. izq.	83.8	88.1	89.3	1.6
Puerta tras. izq.	91.5	90.2	93.4	3.1
Ventanilla del. der.	80.3	86.4	89.1	8.8
Puerta del. der.	89.0	94.8	94.6	12.9
Ventanilla tras. der.	84.5	88.0	88.0	8.0
Puerta tras. der.	87.9	91.4	93.8	0.8
MEDIA	87.9	90.6	91.5	34.6

F1 de detección por pieza (%)

Pieza	YOLO26x-seg (entrenado)	RF-DETR Seg 2XL	DINOv3 ViT-L + decodificador	SAM 3 (zero-shot)
Carrocería	96.4	77.2	98.8	76.6
Matrícula	90.9	93.1	91.6	91.8
Rueda	91.1	93.9	93.7	90.9
Parabrisas	93.4	94.0	94.5	61.2
Luneta	88.6	90.9	91.7	55.0
Ventanilla del. izq.	91.4	90.1	92.9	19.8
Puerta del. izq.	93.6	93.4	93.4	18.5
Ventanilla tras. izq.	92.2	93.3	93.8	21.9
Puerta tras. izq.	92.3	92.5	91.7	0.5
Ventanilla del. der.	91.4	90.5	93.6	3.3
Puerta del. der.	92.6	93.1	92.6	5.9
Ventanilla tras. der.	91.3	93.1	93.6	16.7
Puerta tras. der.	91.3	91.1	90.1	6.0
MEDIA	92.0	91.2	93.2	36.0

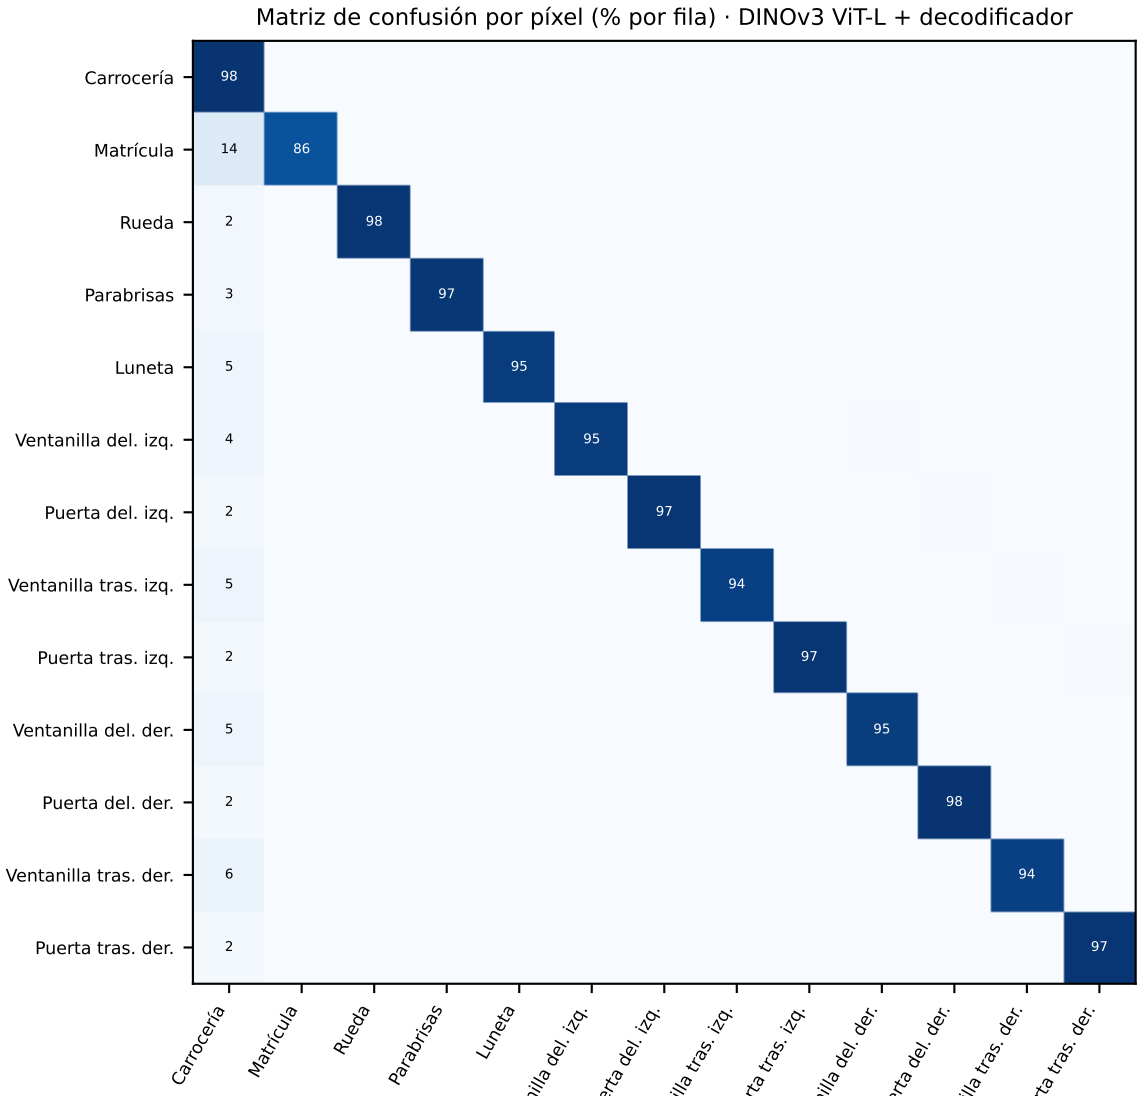
Recall de detección por pieza (%)

Pieza	YOLO26x-seg (entrenado)	RF-DETR Seg 2XL	DINOv3 ViT-L + decodificador	SAM 3 (zero-shot)
Carrocería	93.9	77.1	99.1	76.7
Matrícula	86.3	91.3	91.9	96.3
Rueda	89.5	94.2	94.9	93.7
Parabrisas	91.9	97.1	95.0	93.0
Luneta	84.5	90.7	95.2	90.3
Ventanilla del. izq.	89.8	90.9	93.7	28.7
Puerta del. izq.	91.9	93.1	93.2	24.1
Ventanilla tras. izq.	91.1	92.2	94.8	32.2
Puerta tras. izq.	90.3	91.9	92.8	0.8
Ventanilla del. der.	90.8	92.1	94.7	5.5
Puerta del. der.	91.3	92.0	93.6	9.4
Ventanilla tras. der.	90.9	93.5	95.8	30.0
Puerta tras. der.	89.7	91.0	91.8	9.7
MEDIA	90.2	91.3	94.4	45.4

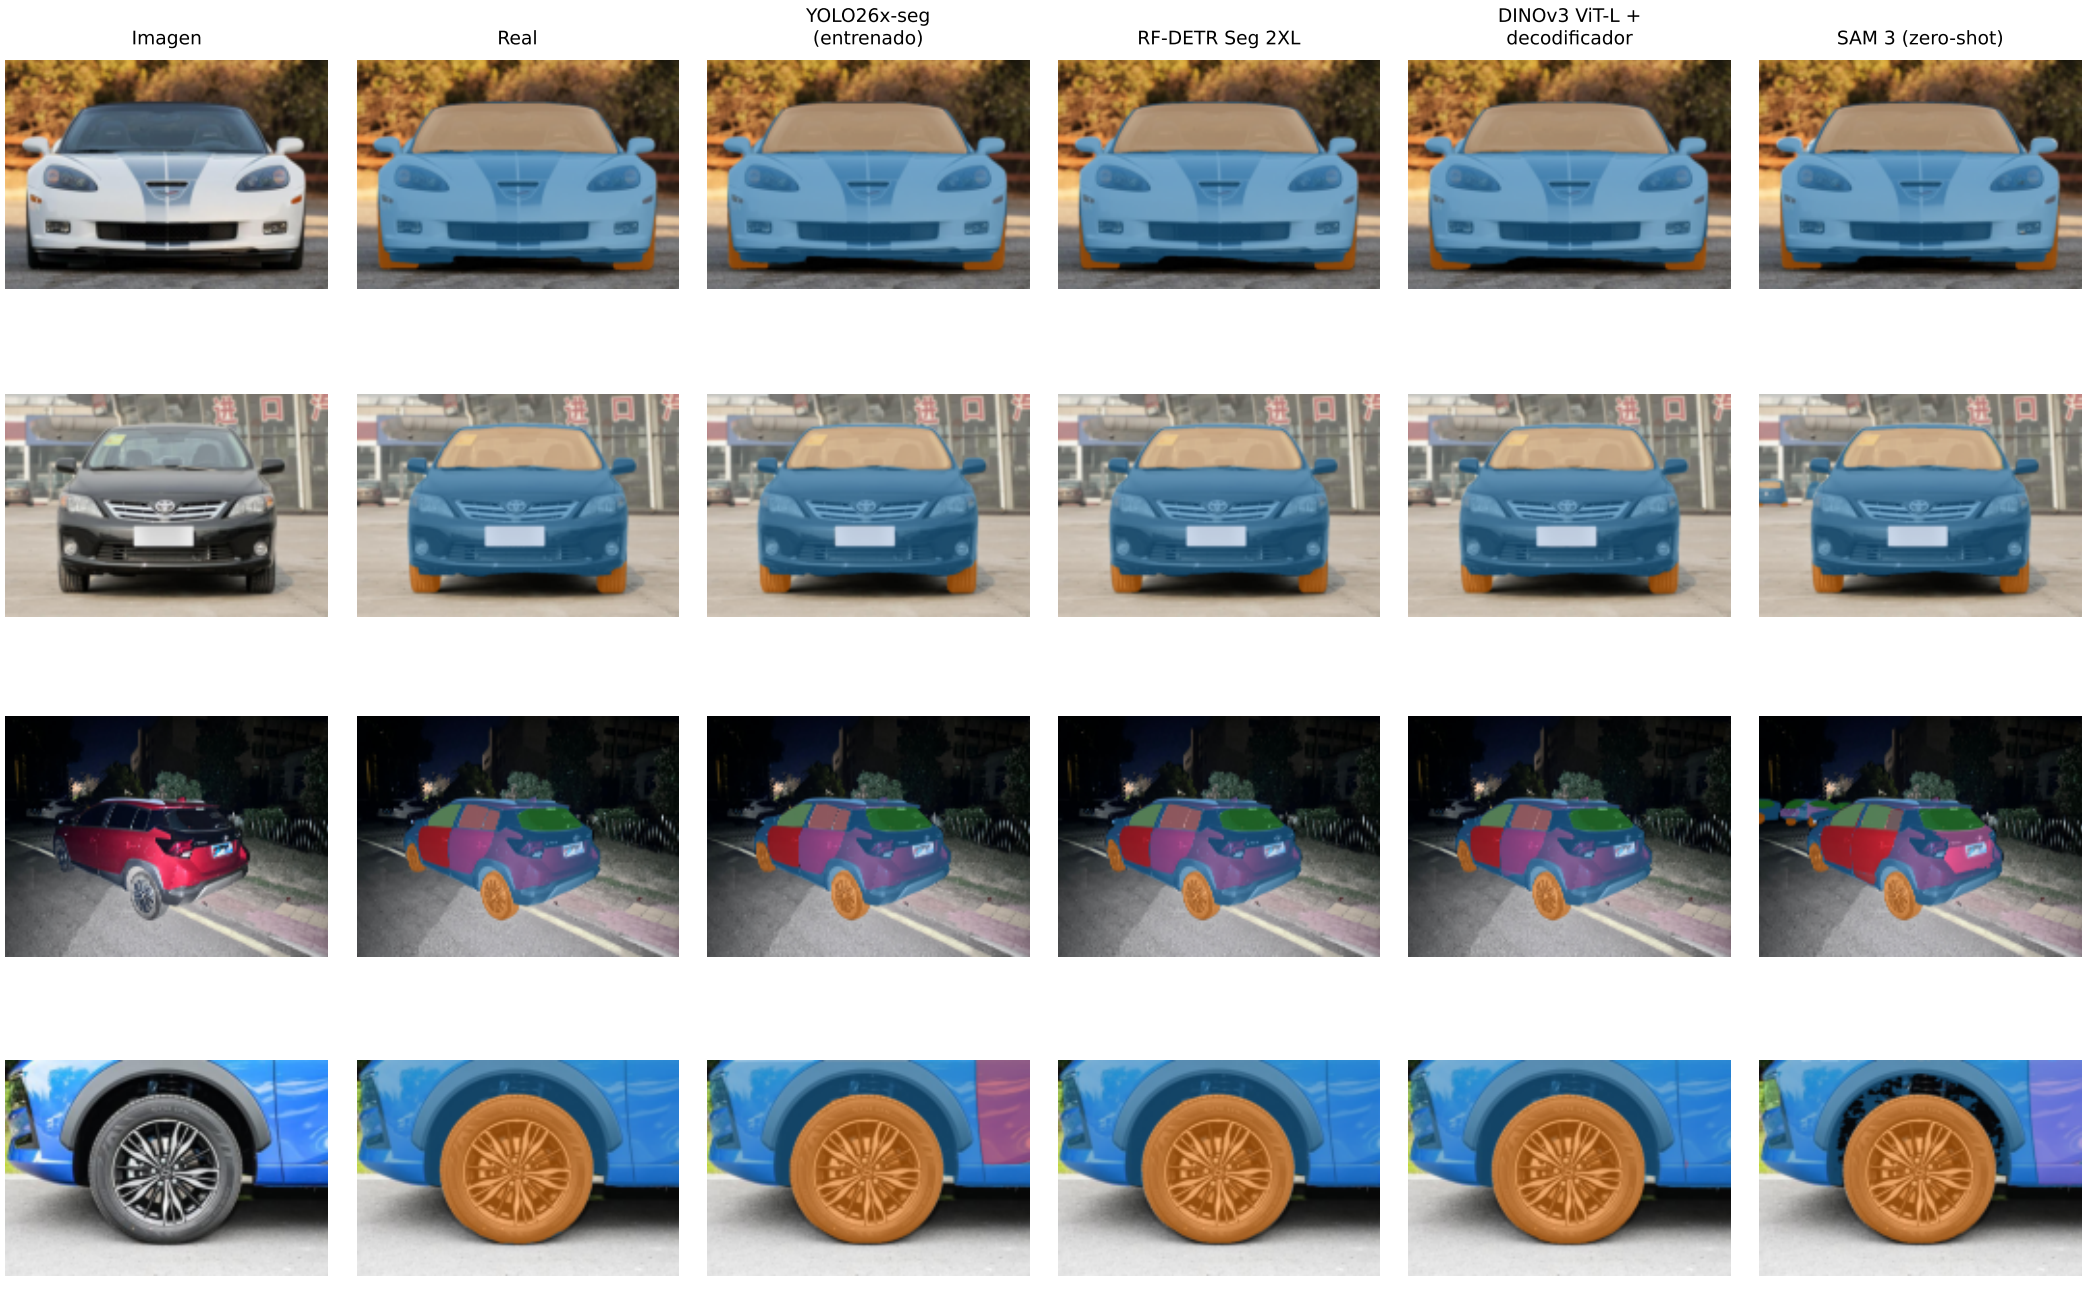
Confusión izquierda/derecha y delante/detrás

% de píxeles de cada par de piezas que el modelo asigna a la pieza contraria. Más bajo es mejor.

Par	YOLO26x-seg (entrenado)	RF-DETR Seg 2XL	DINOv3 ViT-L + decodificador	SAM 3 (zero-shot)
Ventanilla del. izq. ↔ Ventanilla del. der.	0.35	0.72	0.34	21.07
Puerta del. izq. ↔ Puerta del. der.	0.30	0.30	0.30	34.01
Ventanilla tras. izq. ↔ Ventanilla tras. der.	0.32	0.40	0.30	16.21
Puerta tras. izq. ↔ Puerta tras. der.	0.44	0.46	0.37	15.51
Parabrisas ↔ Luneta	0.11	0.46	0.09	2.15



Ejemplos (imágenes aleatorias del test)



Metodología y advertencias

Datos. VehicleSeg10K: 8.596 imágenes de entrenamiento y 3.069 de 'valid', con 13 clases: carrocería, matrícula, rueda, parabrisas, luneta y las cuatro puertas y cuatro ventanillas con su lado. 'Izquierda' es la del coche (punto de vista del conductor), no la de la foto. Todos los modelos se entrenan con 'train' y se evalúan con 'valid', que no se usa para elegir checkpoint (se evalúa el último).

Métricas por píxel. Por cada imagen se hace un mapa de etiquetas: primero la carrocería y encima las piezas, la más confiada al final. Se compara con el PNG oficial. mIoU y mAcc se calculan sobre las 13 clases sin el fondo, acumulando píxeles de todo el test.

mAP. Con una máscara por clase e imagen (la unión de las instancias del modelo con confianza ≥ 0.25) contra una máscara real por clase e imagen, con pycocotools.

YOLO. Ultralytics YOLO26-seg desde pesos COCO, sin volteo horizontal (un volteo cambia izquierda por derecha y estropearía las etiquetas).

RF-DETR. RF-DETR Seg 2XL de Roboflow desde sus pesos preentrenados, 50 épocas, también sin volteo. Se evalúan los pesos EMA de la última época.

DINOv3. Backbone ViT-L/16 de Meta congelado, con un decodificador tipo FPN entrenado encima (40 épocas). Es segmentación semántica pura: da un mapa por píxel, no instancias.

SAM 3. Modelo de Meta guiado por texto, con una consulta por pieza (p. ej. 'left front door'). En zero-shot se usa tal cual, sin entrenar con este dataset; en la versión afinada se entrena con el entrenador oficial y el backbone congelado.